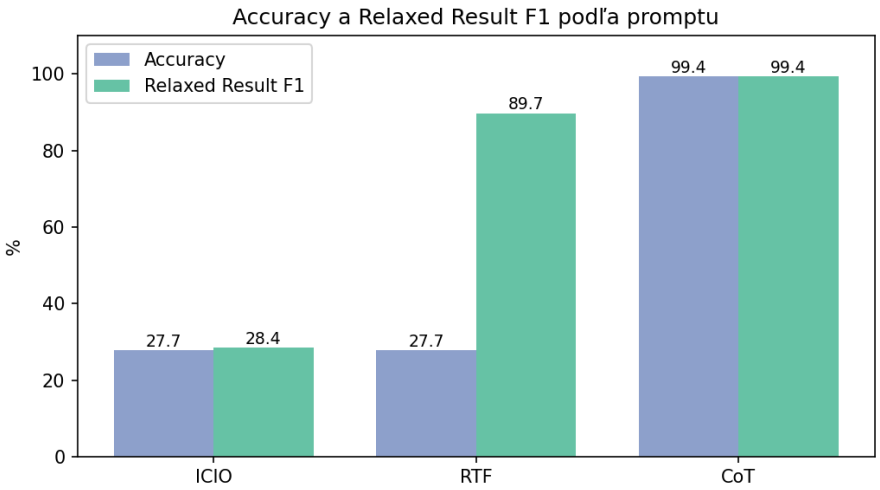
Report – Task 4

Na porovnanie som použila výsledky promptov ICIO, RTF a CoT z Task 2 a 3. Použila som obidve metriky, accuracy z `evaluate_retrieval_predictions.py` a Relaxed Result F1, a pozrela som sa aj na jednotlivé otázky a na to, aké SQL dotazy model generoval. Všetky výpočty a grafy sú v skripte `analysis.py`.

1 Výsledky

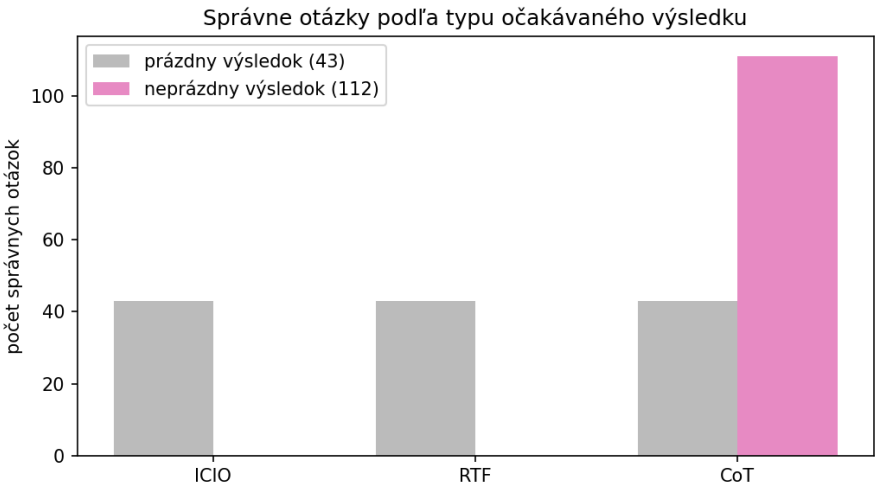
Prompt	Accuracy	Relaxed Result F1	Čas inferencie
ICIO	27,74 % (43/155)	0,284	2 min 50 s
RTF	27,74 % (43/155)	0,897	3 min 15 s
CoT	99,35 % (154/155)	0,994	4 min 10 s

Tabuľka 1: Výsledky promptov



Obr. 1: Accuracy a Relaxed Result F1 podľa promptu

ICIO a RTF mali správne presne tie isté otázky, a to všetkých 43 otázok, pri ktorých je očakávaný výsledok prázdny. Pri ostatných 112 otázkach nemali podľa accuracy správnu ani jednu, CoT mal správnych 111. Ich 27,74 % teda neznamená, že vyriešili štvrtinu úloh.



Obr. 2: Správne otázky podľa typu očakávaného výsledku

2 Prečo nastali rozdiely

Prompt. ICIO a RTF prompt nehovorili, aké stĺpce má dotaz vracať, takže si model vybral sám. Pri ICIO vracal všetky stĺpce z tabuľky RESTAURANT, pri RTF iba názov reštaurácie. Ani jeden nevracal číslo domu, preto pri accuracy neuspeli. RTF však vracal správne reštaurácie, a preto má vysoké Relaxed Result F1. Pri otázkach na najlepšie miesto používali `LIMIT 1`, takže vrátili iba jednu reštauráciu, aj keď ich bolo viac. CoT prompt mal presne napísané, ktoré stĺpce vracať, a obsahoval aj ďalšie informácie o dátach, takže jeho výhoda nie je iba v uvažovaní po krokoch, ale aj v tom, že bol konkrétnejší. Jedinú chybu urobil CoT pri otázke „What is the lifes greates illusion¿‘, kde rozumne vrátil prázdny výsledok, ale dataset očakáva 2696 riadkov.

Model. Všetky prompty používali ten istý model, takže rozdiely nespôsobil on. Podmienky dotazov (mesto, typ jedla, ulica) určoval väčšinou správne, problém bol iba v tom, že nevedel, aký výstup sa od neho čaká.

3 Záver

Najlepší bol CoT prompt. ICIO a RTF mali rovnakú accuracy iba vďaka otázkam s prázdnym výsledkom, ale Relaxed Result F1 ukázala, že RTF otázkam rozumel oveľa lepšie ako ICIO. Hlavným dôvodom rozdielov bolo, ako presne prompt opísal očakávaný výstup.